UNA BREVE STORIA DELL’INTELLIGENZA ARTIFICIALE

Prima della prossima parola

Da un frate catalano a ChatGPT: settecento anni per insegnare a una macchina a indovinare che cosa diremo

Quando scrivete un messaggio sul telefono, sopra la tastiera compaiono tre parole suggerite. Scrivete «buona» e il telefono propone «notte», «giornata», «serata». Non sa che cosa intendete: ha solo visto, milioni di volte, quali parole vengono dopo «buona».

Ecco il segreto, tutto intero: **ChatGPT, Claude e gli altri «modelli linguistici» fanno la stessa cosa**. Leggono un testo e indovinano la parola successiva. Poi quella dopo, e quella dopo ancora. La differenza è che hanno «letto» una porzione enorme di tutto ciò che l’umanità ha scritto, e che il loro modo di indovinare è diventato così raffinato da sembrare pensiero. Se lo sia davvero è una delle domande più affascinanti del nostro tempo, e la lasceremo aperta fino all’ultima pagina.

Questa è la storia di come ci siamo arrivati. Non l’ha inventata una persona sola né un’azienda della Silicon Valley: è una staffetta durata secoli, fatta di filosofi, fisici, matematici litigiosi, spie, ragazzi in fuga e qualche giocoliere. Lungo il percorso trovate tre tipi di riquadri: **per l’informatico** (le formule vere), **per chi ama pensare** (le domande filosofiche) e **curiosità** (per tutti). Si possono saltare senza perdere il filo.

1305 – 1843

1. Il sogno di calcolare il pensiero

Intorno al 1305 il frate maiorchino **Raimondo Lullo** costruì l’*Ars Magna*: dischi di carta concentrici, con sopra scritti concetti come bontà, grandezza, eternità. Ruotandoli si ottenevano tutte le combinazioni possibili. Lullo credeva che così si potessero generare meccanicamente tutte le verità e convertire gli infedeli con la logica invece che con la spada.

Quattro secoli dopo **Gottfried Wilhelm Leibniz**, che di Lullo era un lettore appassionato, sognò una *characteristica universalis*: una lingua di simboli in cui ogni ragionamento diventasse un calcolo. Davanti a una disputa, scriveva, due filosofi non dovrebbero più litigare ma sedersi e dirsi: *Calculemus*, calcoliamo. Leibniz descrisse anche l’aritmetica binaria (1703), quella fatta solo di 0 e 1 che oggi parla dentro ogni computer, e la regola della catena delle derivate, che ritroveremo nel 1986.

Nel 1843 **Ada Lovelace**, figlia del poeta Byron, tradusse e annotò un articolo sulla Macchina Analitica di **Charles Babbage**, un calcolatore meccanico mai costruito. Nelle sue note scrisse quello che molti considerano il primo programma della storia e intuì che una macchina del genere potrebbe manipolare non solo numeri, ma qualunque simbolo, perfino note musicali. Ma aggiunse un avvertimento: la macchina *non ha alcuna pretesa di creare* nulla, fa solo ciò che le ordiniamo di fare.

CURIOSITÀ

Nel 1726 Jonathan Swift, nei *Viaggi di Gulliver*, prese in giro proprio questo sogno. Nell'Accademia di Lagado un professore ha una macchina coperta di tessere di legno con tutte le parole della lingua: gli studenti girano delle manovelle, le parole si rimescolano, e quando per caso compaiono tre o quattro parole di fila che hanno senso le trascrivono. Così, promette il professore, chiunque potrà scrivere libri di filosofia e poesia senza alcun talento. Era satira. Tre secoli dopo, è quasi una descrizione tecnica: mancava solo il modo di scegliere le parole *non* a caso.

1870 – 1906

2. Una formula scolpita su una tomba

Sembra strano, ma uno dei mattoni dell'intelligenza artificiale viene dalla fisica dei gas. Il viennese **Ludwig Boltzmann** voleva capire perché il calore passa sempre dal caldo al freddo e mai al contrario. La sua risposta fu statistica: un gas è fatto di miliardi di molecole, e il disordine vince semplicemente perché i modi di essere disordinati sono infinitamente più numerosi di quelli di essere ordinati. Misurò questo disordine con una formula, l'**entropia**, che oggi è incisa sulla sua tomba nel cimitero centrale di Vienna:

$$S = k \cdot \log W$$

Boltzmann ricavò anche una regola per calcolare quanto è probabile che una molecola si trovi in un certo stato in base alla sua energia e alla temperatura. Teniamola a mente: è la stessa regola che oggi decide quale parola sceglie ChatGPT. Boltzmann morì nel 1906, amareggiato dagli attacchi di chi non credeva nemmeno all'esistenza degli atomi. Nello stesso anno, a San Pietroburgo, un matematico pubblicava l'idea da cui parte davvero la nostra storia.

PER L'INFORMATICO

La distribuzione di Boltzmann, $P(i) \propto e^{-E_i/kT}$, è identica alla **softmax** che chiude ogni Transformer: $P(\text{token}_i) = e^{z_i/T} / \Sigma_j e^{z_j/T}$. I logit z prendono il posto dell'energia (col segno cambiato) e il parametro **temperature** delle API è letteralmente la T di Boltzmann: alta temperatura, scelte più disordinate e creative; bassa temperatura, risposte più prevedibili.

1906 – 1913

3. Il matematico ribelle che contava le vocali di Puškin

Andrej Markov era un professore di San Pietroburgo dal carattere impossibile. Nel 1912, quando la Chiesa ortodossa scomunicò Lev Tolstoj, Markov chiese per iscritto di essere scomunicato anche lui, per solidarietà. Ma la sua lite più feconda fu con un collega moscovita, **Pavel Nekrasov**, matematico e uomo molto religioso.

Nekrasov sosteneva una tesi audace: la «legge dei grandi numeri» (quella per cui, lanciando una moneta mille volte, le teste si avvicinano alla metà) funziona solo con eventi indipendenti. Le statistiche sociali, come i tassi di criminalità, seguono quella legge; dunque le scelte umane sono indipendenti; dunque il libero arbitrio esiste, ed è dimostrato dalla matematica. Markov trovò il ragionamento insopportabile e, nel 1906, per smontarlo inventò un oggetto nuovo: una **catena** di eventi in cui ognuno dipende da quello precedente, e che tuttavia obbedisce lo stesso alla legge dei grandi numeri.

Nel 1913 volle mostrare che le sue catene esistevano nel mondo reale. Prese l'*Evgenij Onegin* di Puškin, il poema nazionale russo, e contò a mano le prime 20.000 lettere, annotando se ogni vocale o consonante era seguita da una vocale o da una consonante. Scoprì che circa il 43% delle lettere erano vocali, ma che dopo una vocale ne arrivava un'altra solo una volta su

otto, mentre dopo una consonante una vocale arrivava due volte su tre. La lettera successiva *dipende* da quella prima. Era il primo modello statistico del linguaggio della storia, fatto con carta, matita e molta ostinazione.

PER CHI AMA PENSARE

La prima idea dell'AI linguistica nasce da una disputa sul **libero arbitrio**. Nekrasov usava la probabilità per difendere la libertà umana; Markov per mostrare che regolarità e dipendenza convivono. Oggi la domanda si è rovesciata: se una macchina che prevede la parola successiva riesce a scrivere come noi, che cosa dice questo del *nostro* modo di parlare? Siamo anche noi, in parte, catene di Markov?

1936 – 1952

4. Turing: «Le macchine possono pensare?»

Nel 1936 un ventiquattrenne di Cambridge, **Alan Turing**, descrisse una macchina immaginaria: un nastro, una testina che legge e scrive simboli, poche regole. Dimostrò che una macchina così semplice può eseguire *qualunque* calcolo che possa essere descritto da una procedura. Senza volerlo, aveva definito che cos'è un computer prima che ne esistesse uno. Durante la guerra, a Bletchley Park, contribuì in modo decisivo a decifrare i messaggi della macchina tedesca Enigma.

Nel 1950 pubblicò l'articolo che apre con la domanda più famosa dell'informatica: le macchine possono pensare? Trovandola troppo vaga, la sostituì con un gioco, il **gioco dell'imitazione**: se conversando per iscritto non riusciamo a distinguere una macchina da un essere umano, che diritto abbiamo di dire che non pensa? Turing previde che verso il 2000 un interrogatore medio, dopo cinque minuti di conversazione, non avrebbe avuto più del 70% di probabilità di indovinare. Nello stesso articolo rispose una per una alle obiezioni, compresa quella che chiamò «l'obiezione di Lady Lovelace»: una macchina non può fare nulla di nuovo. La sua replica: anche le macchine, spesso, ci sorprendono.

CURIOSITÀ

Turing scrisse uno dei primi programmi di scacchi quando non esisteva ancora un computer capace di eseguirlo. Nel 1952 lo «eseguì» lui stesso, a mano, su carta, contro un collega: impiegava circa mezz'ora per ogni mossa. Perse. Turing morì nel 1954, due anni dopo essere stato condannato per la sua omosessualità; il governo britannico gli ha chiesto scusa ufficialmente solo nel 2009.

1943 – 1951

5. Neuroni di carta e il gioco della prossima lettera

Nel 1943 un neurologo, **Warren McCulloch**, e un ragazzo di diciannove anni senza laurea, **Walter Pitts**, pubblicarono il primo modello matematico di un neurone: una piccola unità che riceve segnali, li somma e «si accende» se superano una soglia. Mostrarono che reti di questi neuroni semplificati possono calcolare qualunque funzione logica. Il cervello, almeno in linea di principio, poteva diventare matematica.

CURIOSITÀ

La storia di Pitts, come la raccontano i suoi biografi, sembra un romanzo. A dodici anni, a Detroit, si nascose per tre giorni in una biblioteca per sfuggire ai bulli e lesse i *Principia Mathematica* di Russell e Whitehead, tre volumi di logica quasi illeggibili. Trovò alcuni errori e scrisse a Bertrand Russell, che gli rispose invitandolo a studiare con lui in Inghilterra. Pitts non frequentò mai ufficialmente l'università.

Nel 1948, ai Bell Labs, **Claude Shannon** pubblicò *Una teoria matematica della comunicazione*. Fino ad allora «informazione» era una parola vaga; Shannon la rese

misurabile. L'informazione, disse, è **sorpresa**: un messaggio che potevi prevedere non ti dice nulla, uno inatteso ti dice molto. Misurò la sorpresa con una formula che somigliava in modo impressionante a quella di Boltzmann, e la chiamò anch'essa entropia. Si racconta che fu il grande matematico John von Neumann a suggerirgli il nome: tanto, gli avrebbe detto, nessuno sa davvero che cosa sia l'entropia, e in ogni discussione avrai sempre il vantaggio.

In quello stesso articolo Shannon fece un esperimento che oggi suona profetico. Generò frasi «finte» in inglese scegliendo ogni parola in base alla precedente, con probabilità prese da un libro. Ne uscivano cose come *«THE HEAD AND IN FRONTAL ATTACK ON AN ENGLISH WRITER...»*: prive di senso, eppure con il suono dell'inglese. Nel 1951 andò oltre: chiese a delle persone di indovinare un testo lettera per lettera e da quanti tentativi servivano stimò quanta informazione contiene davvero l'inglese. **È esattamente il compito su cui oggi si allenano gli LLM**, con la differenza che a indovinare non è una persona ma una rete neurale, e i testi sono miliardi.

PER L'INFORMATICO

Entropia di Shannon: $H = -\Sigma\, p(x) \log_2 p(x)$, in bit. Da qui discende la **cross-entropia**, la funzione di perdita con cui si addestra ogni LLM: $L = -\Sigma_t \log P(w_t \mid w_1 \ldots w_{t-1})$. La *perplexity* che trovi nei paper è semplicemente 2^H (o e^L): il numero medio di parole tra cui il modello è «indeciso». Lo schema di Shannon del 1948 con le approssimazioni di ordine zero, uno e due è di fatto un modello a **n-grammi**.

CURIOSITÀ

Shannon era un personaggio: girava per i corridoi dei Bell Labs in monociclo, a volte facendo il giocoliere. Nel 1950 costruì Theseus, un topo meccanico che imparava a uscire da un labirinto e si ricordava la strada: una delle prime macchine al mondo capaci di imparare.

1955 – 1990

6. Nasce l'«intelligenza artificiale»: entusiasmi e inverni

Nell'agosto del 1955 quattro ricercatori, **John McCarthy, Marvin Minsky, Nathan Rochester** e lo stesso **Shannon**, scrissero la proposta per un seminario estivo al Dartmouth College, nel New Hampshire. Per descriverlo McCarthy coniò un'espressione nuova: *artificial intelligence*. Il seminario si tenne nell'estate del 1956, ed è considerato l'atto di nascita della disciplina. La proposta era di un ottimismo commovente: si pensava di fare progressi significativi in due mesi, con dieci persone.

Nel 1958 lo psicologo **Frank Rosenblatt** presentò il **percettrone**, una macchina con neuroni artificiali che imparava a riconoscere forme. Il *New York Times* riportò che la Marina americana si aspettava di ottenerne presto un computer capace di camminare, parlare, vedere, scrivere, riprodursi ed essere cosciente della propria esistenza. Nel 1969 Minsky e Seymour Papert pubblicarono un libro che mostrava i limiti matematici del percettrone semplice; i finanziamenti alle reti neurali crollarono. Rosenblatt morì nel 1971 in un incidente in barca, il giorno del suo compleanno, senza vedere la rivincita delle sue idee. Seguirono anni di disillusione che gli addetti ai lavori chiamano gli **inverni dell'AI**.

Intanto, nel 1966, al MIT, **Joseph Weizenbaum** scrisse **ELIZA**, un programma di poche centinaia di righe che imitava uno psicoterapeuta rigirando le frasi dell'utente («Mi sento triste.» «Perché ti senti triste?»). Weizenbaum rimase sconvolto quando la sua segretaria, che sapeva benissimo come funzionava, gli chiese di uscire dalla stanza per poter parlare con ELIZA in privato. Da quel momento divenne uno dei critici più severi dell'AI.

PER CHI AMA PENSARE

L'**effetto ELIZA** è la nostra tendenza ad attribuire comprensione ed emozioni a qualunque cosa ci risponda con parole sensate. Nel 1980 il filosofo John Searle propose l'esperimento della **stanza cinese**: un uomo chiuso in una stanza riceve fogli in cinese e, seguendo un enorme manuale di regole, restituisce risposte perfette senza capire una parola. Il sistema «capisce» il cinese? Per Searle no: manipolare simboli non è comprendere. Per i suoi critici a capire è l'intero sistema, uomo più manuale. Con gli LLM questo esperimento mentale è diventato, quasi, un esperimento reale.

Le reti neurali tornarono nel 1986, quando **David Rumelhart, Geoffrey Hinton** e **Ronald Williams** resero popolare la **retropropagazione** (*backpropagation*): un metodo per correggere una rete un pochino alla volta, partendo dai suoi errori e risalendo all'indietro strato per strato. Nello stesso periodo, all'IBM, il gruppo di **Frederick Jelinek** dimostrò che per il riconoscimento vocale la statistica funzionava meglio delle regole grammaticali scritte a mano. A Jelinek è attribuita una battuta rimasta celebre: ogni volta che licenzio un linguista, le prestazioni del sistema migliorano.

1953 – 2013

7. Le parole diventano luoghi

Come si spiega a un computer che cosa significa «gatto»? La risposta venne, sorprendentemente, dalla filosofia e dalla linguistica. **Ludwig Wittgenstein**, nelle *Ricerche filosofiche* (1953), sostenne che il significato di una parola è il suo **uso** nella lingua. Il linguista **Zellig Harris** (1954) osservò che parole con significati simili compaiono in contesti simili, e il britannico **J. R. Firth** (1957) lo riassunse in una frase diventata il motto della disciplina:

«You shall know a word by the company it keeps»

Conoscerai una parola dalla compagnia che frequenta

Nel 2003 **Yoshua Bengio** unì finalmente i due filoni della nostra storia, quello probabilistico di Markov e Shannon e quello neurale di McCulloch, Pitts e Rosenblatt: costruì il primo modello linguistico neurale, una rete che prevedeva la parola successiva imparando, intanto, a rappresentare ogni parola come un punto in uno spazio. Nel 2013 **Tomas Mikolov** e colleghi, con **word2vec**, resero questa idea veloce e popolare, e scoprirono qualcosa di quasi magico: in quello spazio i significati si comportano come geometria. Partite dal punto «re», togliete la direzione «uomo», aggiungete la direzione «donna», e arrivate vicino a «regina».

PER L'INFORMATICO

Gli **embedding** sono vettori densi (centinaia o migliaia di dimensioni). La vicinanza semantica si misura con la similarità del coseno, $\cos\theta = (A \cdot B) / (\|A\|\,\|B\|)$. L'analogia $v_{re} - v_{uomo} + v_{donna} \approx v_{regina}$ funziona cercando il vicino più prossimo ed escludendo le parole di partenza. È l'ipotesi distribuzionale di Harris e Firth tradotta in algebra lineare: il vettore di una parola *è* la sintesi dei contesti in cui compare.

PER CHI AMA PENSARE

È un piccolo trionfo postumo di Wittgenstein: le macchine hanno imparato il significato delle parole esattamente come lui suggeriva, osservandone l'uso, senza definizioni né dizionari. Resta la domanda che lui stesso avrebbe posto: conoscere tutti gli usi di «dolore» equivale a sapere che cos'è il dolore?

2014 – oggi

8. «Attention Is All You Need»

Restava un problema. Leggendo una frase lunga, i modelli dimenticavano l'inizio. Nel 2014 **Dzmitry Bahdanau**, Kyunghyun Cho e Bengio introdussero l'**attenzione**: invece di ricordare tutto, il modello impara a «guardare indietro» verso le parole che contano. Nella frase «Il gatto ha mangiato il topo perché *aveva* fame», per capire chi aveva fame bisogna prestare attenzione a «gatto», non a «topo».

Nel 2017 otto ricercatori di Google pubblicarono un articolo dal titolo scherzoso, che fa il verso alla canzone dei Beatles: *Attention Is All You Need*, l'attenzione è tutto ciò che serve. Proponevano un'architettura nuova, il **Transformer**, fatta quasi solo di attenzione: ogni parola guarda contemporaneamente tutte le altre. Il dettaglio decisivo era pratico: questo calcolo si poteva fare tutto in parallelo sulle schede grafiche, le stesse dei videogiochi. Per la prima volta si poteva allenare un modello su quantità di testo prima impensabili.

PER L'INFORMATICO

Scaled dot-product attention: $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V$. Ogni token produce una *query* (cosa cerco), una *key* (cosa offro) e un *value* (cosa trasmetto). La divisione per $\sqrt{d_k}$ evita che i prodotti scalari crescano con la dimensione e saturino la softmax, appiattendo i gradienti. Nei decoder come GPT una *maschera causale* impedisce a ogni token di guardare il futuro: è la regola della catena di Markov e Shannon, $P(w_t \mid w_{<t})$, ma con un contesto di migliaia di token invece che di uno o due.

Da lì la corsa è stata vertiginosa. Nel 2018 OpenAI presentò **GPT**; nel 2019 annunciò GPT-2 ma inizialmente non lo rese pubblico per intero, ritenendolo potenzialmente pericoloso; nel 2020 **GPT-3** aveva 175 miliardi di parametri, cioè di «manopole» regolate durante l'allenamento. Il 30 novembre 2022 arrivò **ChatGPT**: secondo le stime, in circa due mesi raggiunse cento milioni di utenti, la crescita più rapida mai vista per un'applicazione. Seguirono Claude, Gemini, LLaMA e molti altri.

CURIOSITÀ

Nel 2024 il premio Nobel per la fisica è andato a **John Hopfield** e **Geoffrey Hinton** per le reti neurali. Tra i lavori citati c'è la **macchina di Boltzmann** di Hinton (1985), che porta il nome del fisico del capitolo 2. Il cerchio si chiude: un'idea nata per spiegare i gas è tornata alla fisica passando per il linguaggio. E sotto l'articolo del Transformer c'è una nota che dichiara gli otto autori contributori alla pari, elencati in ordine casuale.

Epilogo

9. Che cosa abbiamo costruito?

Ricapitoliamo con le parole più semplici possibili. Un LLM è un sistema che ha letto moltissimo e ha imparato una sola abilità: dato un testo, stimare quali parole è probabile che vengano dopo. L'idea è di **Markov** (1913). Il modo di misurare quanto bene indovina è di **Shannon** (1948). Il modo di scegliere la parola viene da **Boltzmann** (anni '70 dell'Ottocento). I neuroni artificiali da **McCulloch e Pitts** (1943), il modo di allenarli dal 1986, le parole come luoghi dal 2003-2013, l'attenzione dal 2014-2017. Nessuno ha «inventato» ChatGPT: lo hanno costruito, senza saperlo, generazioni di persone che si occupavano d'altro.

La domanda di Ada Lovelace e di Turing, però, è ancora aperta. Nel 2021 un gruppo di linguiste e ricercatrici, tra cui Emily Bender e Timnit Gebru, ha descritto questi modelli come «**pappagalli stocastici**»: sistemi che ricombinano forme linguistiche secondo probabilità, senza accesso al significato. Altri ricercatori obiettano che per prevedere bene la parola successiva in un trattato di chimica o in una dimostrazione bisogna aver catturato, in qualche

forma, la struttura del mondo che quelle parole descrivono. Il dibattito è aperto, ed è uno dei pochi luoghi in cui oggi filosofi e ingegneri lavorano davvero sulla stessa domanda.

PER CHI AMA PENSARE

Tre domande da portarsi via. **1.** Se capire significa saper usare le parole in modo appropriato (Wittgenstein), questi sistemi capiscono? Se significa altro, che cosa esattamente? **2.** Lullo e Leibniz sognavano di ridurre il pensiero a calcolo. Ci siamo riusciti, o abbiamo scoperto che una parte del linguaggio era già calcolo? **3.** L'obiezione di Lady Lovelace, la macchina non crea nulla, regge ancora davanti a un sistema che ha letto tutto ciò che abbiamo scritto e lo ricombina in modi che nessuno aveva previsto?

IN BREVE

Cronologia essenziale

c. 1305	Raimondo Lullo, *Ars Magna*: combinare concetti con dischi rotanti.
1676 – 1703	Leibniz: regola della catena delle derivate, sogno del *Calculemus*, aritmetica binaria.
1726	Swift, *I viaggi di Gulliver*: la macchina di Lagado che scrive libri a caso (satira).
1843	Ada Lovelace annota la Macchina Analitica di Babbage: primo programma, «la macchina non crea».
1847	Cauchy descrive la discesa del gradiente, il metodo con cui oggi si allenano le reti.
1870 – 1900	Boltzmann e Gibbs: entropia e distribuzione di Boltzmann (l'antenata della softmax).
1906	Markov inventa le catene di eventi dipendenti, per confutare Nekrasov. Muore Boltzmann.
1913	Markov conta 20.000 lettere dell'*Evgenij Onegin*: primo modello statistico di un testo.
1924 – 1928	Nyquist e Hartley (Bell Labs): prime misure quantitative dell'informazione.
1936	Turing descrive la macchina universale: la definizione teorica di computer.
1943	McCulloch e Pitts: primo modello matematico del neurone.
1948	Shannon, teoria dell'informazione: entropia e testi generati con n-grammi. Wiener, *Cybernetics*.
1950	Turing, *Computing Machinery and Intelligence*: il gioco dell'imitazione. Shannon costruisce Theseus.
1951	Shannon stima l'entropia dell'inglese facendo indovinare la lettera successiva.
1953 – 1957	Wittgenstein (significato come uso), Harris e Firth: l'ipotesi distribuzionale.
1955 – 1956	Proposta e seminario di Dartmouth: nasce il termine *artificial intelligence*.
1958	Rosenblatt: il percettrone.
1966	Weizenbaum: ELIZA, e la scoperta dell'«effetto ELIZA».
1969 – 1980	Minsky e Papert, *Perceptrons*; rapporto Lighthill (1973): il primo inverno dell'AI.
1980	Searle: l'esperimento mentale della stanza cinese.
1985 – 1986	Hinton e colleghi: macchina di Boltzmann; Rumelhart, Hinton e Williams rendono popolare la backpropagation.
anni '80 – '90	Jelinek e IBM: modelli statistici a n-grammi per voce e traduzione.
2003	Bengio: primo modello linguistico neurale con rappresentazioni distribuite delle parole.
2012	AlexNet: le reti profonde su GPU stravincono nel riconoscimento di immagini; inizia il *deep learning*.
2013	Mikolov e colleghi, word2vec: re − uomo + donna ≈ regina.
2014	Bahdanau, Cho e Bengio: il meccanismo di attenzione.
2017	Vaswani e colleghi (Google), *Attention Is All You Need*: nasce il Transformer.
2018 – 2020	GPT (2018), BERT (2018), GPT-2 (2019), GPT-3 con 175 miliardi di parametri (2020).
2021	Bender, Gebru e colleghi: l'articolo sui «pappagalli stocastici».
2022	30 novembre: ChatGPT. L'AI generativa entra nella vita quotidiana.
2023 – oggi	Claude, Gemini, LLaMA e molti altri modelli; nel 2024 Nobel per la fisica a Hopfield e Hinton.

Nota sulle fonti: i fatti e le date sono documentati nella storia della disciplina. Gli aneddoti segnati con «si racconta» o «è attribuita» (von Neumann e il nome «entropia», la battuta di Jelinek, alcuni dettagli della giovinezza di Pitts) sono tramandati da testimoni e biografi ma non verificabili con certezza assoluta.